

## 9. Bezkontextové jazyky. Bezkontextové gramatiky a zásobníkové automaty. Normální formy bezkontextových gramatik. Převod bezkontextové gramatiky na zásobníkové automaty. Použití pumping lemmatu a uzávěrových vlastností bezkontextových jazyků.

### Bezkontextové jazyky a gramatiky

Bezkontextový jazyk je jazyk generovaný bezkontextovou gramatikou.

Pro připomenutí, bezkontextová gramatika je gramatika, ve které jsou všechna pravidla ve tvaru  $A \rightarrow w$ , kde  $w$  může být složeno z terminálů i neterminálů.

Jazyk  $L$  je bezkontextový, pokud existuje bezkontextová gramatika  $G$  taková, že  $L(G) = L$ .  
Bezkontextová gramatika (CFG)  $G$  je čtveřice  $(N, \Sigma, P, S)$ , kde:

- $N$  je neprázdná konečná množina neterminálních symbolů
- $\Sigma$  je konečná množina terminálních symbolů taková, že  $N \cap \Sigma = \emptyset$
- $P \subseteq N \times V^*$  je konečná množina pravidel ( $V = N \cup \Sigma$ )
- $S \in N$  je počáteční neterminál

Současně třída jazyků rozpoznávaných zásobníkovými automaty je právě třída bezkontextových jazyků. Tj. jazyk  $L$  je bezkontextový, pokud je akceptován nějakým zásobníkovým automatem (existuje zásobníkový automat  $M$ , takový, že  $L(M) = L$ ).

Bezkontextové jazyky lze reprezentovat:

- bezkontextovou gramatikou
- zásobníkovým automatem
- rozšířeným zásobníkovým automatem

Bezkontextové jazyky mají zásadní význam v definici syntaxe programovacích jazyků, lze zapisovat např. aritmetické výrazy, programové bloky atd.

Způsob jak se taková slova z gramatik vygenerují lze zapsat např. pomocí derivačních stromů.

### Derivační stromy

V gramatice je možné, aby různé derivace byly ekvivalentní v tom smyslu, že všechny tyto derivace používají stejná pravidla na stejných místech, tj. jsou aplikována na stejné výskyty neterminálů, avšak v různém pořadí. Zatímco definice takové ekvivalence je pro gramatiky typu 0 poněkud komplikovaná, lze v případě bezkontextových gramatik zavést pro třídu ekvivalentních derivací jednoduchou grafovou reprezentaci, tzv. derivační strom (někdy též zvanou strom odvození). Alternativně lze reprezentovat ve výše uvedeném smyslu ekvivalentní derivace jistými *kanonickými* derivacemi, v nichž aplikujeme pravidla jistým standardizovaným postupem (např. v každém kroku derivace přepisujeme ve větě formě

Derivační strom má **výsledek**, což je uspořádání listů v pořadí zleva doprava. Ze stromu tak vznikají **levé** nebo **pravé** derivace podle toho jestli se přepisuje vždy buď nejlevější nebo nejpravější neterminál.

Odpovídající gramatika může být:

- **Jednoznačná** – pokud v jazyce neexistuje slovo, které by mělo dva nebo více derivačních stromů
- **Víceznačná** – v opačném případě

Jazyk se nazývá vnitřně víceznačný, právě když každá gramatika, která jej generuje, je víceznačná.

Příkladem může být gramatika výrazů z abecedy  $a, +, 1$ .

- (1)  $S \rightarrow S + S$
- (2)  $S \rightarrow 1$
- (3)  $S \rightarrow a$

jejíž derivační strom vypadá takto:



tato gramatika je samozřejmě víceznačná.

Bezkontextové gramatiky se pro další použití většinou upravují do speciálních tvarů.

## Normální (kanonické) tvary CFG

### Redukované bezkontextové gramatiky (bez nepoužitelných symbolů)

Symbol  $X \in N \cup \Sigma$  je nepoužitelný v CFG  $G = (N, \Sigma, P, S)$  právě když v  $G$  neexistuje derivace tvaru

$$S \Rightarrow^* wXy \Rightarrow^* wxy$$

pro žádné  $w, x, y \in \Sigma^*$ . Řekneme, že  $G$  je redukovaná, jestliže neobsahuje žádné nepoužitelné symboly.

Nepoužitelný symbol (terminál či neterminál) může být dvojího druhu:

- $X$  je nepoužitelný typu I (nenormovaný)  $\iff$  neexistuje  $w \in \Sigma^*$  splňující  $X \Rightarrow^* w$  (z  $X$  nelze vyderivovat žádný terminál)

- $X$  je nepoužitelný typu II (nedosažitelný)  $\iff$  neexistují  $\alpha, \beta \in (N \cup \Sigma)^*$  splňující  $S \Rightarrow^* \alpha X \beta$  ( $X$  se nevyskytuje v žádné větě formě)

Pro eliminaci nepoužitelných symbolů existuje algoritmus.

Každý neprázdný bezkontextový jazyk je generovaný nějakou redukovanou CFG.

### Gramatiky bez $\varepsilon$ -pravidel

Nejsou zde  $\varepsilon$ -pravidla, nebo je zde jen jedno pravidlo  $S \rightarrow \varepsilon$ , a  $\varepsilon$  není na pravé straně žádného pravidla.

### Gramatiky bez jednoduchých pravidel

Nejsou zde pravidla  $A \rightarrow B$ , kde  $A, B \in N$ .

### Necyklické, vlastní a rekursivně gramatiky

CFG  $G = (N, \Sigma, P, S)$  se nazývá **necyklická**, právě když neexistuje  $A \in N$  takový, že  $A \Rightarrow^+ A$ .

$G$  se nazývá **vlastní**, právě když je bez nepoužitelných symbolů, bez  $\varepsilon$ -pravidel a necyklická.

Ke každému neprázdnému bezkontextovému jazyku existuje **vlastní** bezkontextová gramatika, která jej generuje

Neterminál  $A$  v CFG  $G = (N, \Sigma, P, S)$  se nazývá **rekursivní** jestliže v  $G$  existuje derivace  $A \Rightarrow^+ \alpha A \beta$ . Je-li  $\alpha = \varepsilon$  resp.  $\beta = \varepsilon$ , pak  $A$  se nazývá levorekursivní resp. pravorekursivní. CFG bez levorekursivních terminálů se nazývá nelevorekursivní.  $\alpha, \beta$  jsou levé strany pravidel v  $P$ .

### Chomského NF

Gramatika je v CNF, právě když je bez  $\varepsilon$ -pravidel a obsahuje jen pravidla

- $A \rightarrow BC, B, C$
- $A \rightarrow a$
- $S \rightarrow \varepsilon$

Každý CFL lze generovat gramatikou v CNF.

Ve zkratce algoritmus funguje tak, že pravé strany délky větší než 2 nahradí novými neterminály, a tak se tato pravá strana zkrátí. Například pravidlo  $X \rightarrow ABC$  se změní na pravidla  $X \rightarrow A\langle BC \rangle, \langle BC \rangle \rightarrow BC$  ( $\langle BC \rangle$  je nový neterminál). Pro pravé strany délky 2, které se skládají z terminálu a neterminálu nahradí terminál novým neterminálem. Např.  $X \rightarrow aC$  se změní na  $X \rightarrow \langle a \rangle C, \langle a \rangle \rightarrow a$ .

Výhodou CNF je, že jejich uzly mají vždy dva potomky, pokud se nejedná o listy. Takové stromy, kde je největší délka  $j$  mají právě  $2^j$  listů, ovšem v CNF je počet listů roven počtu jejich přímých předků, tj. mají  $2^{(j-1)}$  listů.

## Greibachové NF

Gramatika je v GNF, pokud je bez  $\epsilon$ -pravidel a pokud dále obsahuje jen pravidla

- $A \rightarrow a\alpha$ , kde  $a$  terminál a  $\alpha$  je řetězec neterminálů.

Každý CFL lze generovat CFG v GNF.

Velmi zhruba naznačený postup je následující: Pokud je  $L(G)$  prázdný, pak jej definujeme jako jediné pravidlo ( $S \rightarrow aS$ ). Pokud je  $L(G)$  neprázdný, odstraníme levou rekurzi a převedeme do GNF.

## Použití pumping lemmatu pro CFL

Nechť  $L$  je CFL. Pak existují přirozená čísla  $p, q$  taková, že každé slovo  $z \in L$ ,  $|z| > p$  lze psát ve tvaru  $z = uvwxy$ , kde

- alespoň jedno ze slov  $v, x$  je neprázdné
- $|vwx| \leq q$
- $uv^iwx^iy$  je z  $L$  pro všechna  $i \geq 0$ .

Tvrzení zůstává v platnosti i když namísto konstant  $p, q$  budeme všude psát jen jedinou konstantu  $n$ .

Důkaz pro jazyk  $L = \{a^j b^j c^j : j > 0\}$ , že není CFL.

1. Předpokládejme, že je CFL
2. Zvolíme  $p = q = n$
3. Přemýšlíme jak slovo zapsat, aby splňovalo podmínky lemmatu, ale po napumpování přestalo patřit do jazyka  $L$ .
4. Protože platí, že  $|vwx| \leq q$  a  $q = n$ , nemůže se stát, že bychom do  $vwx$  dokázali nějakým způsobem nacpat všechny tři znaky. Tj. bude tam buď  $a$  nebo  $b$  nebo  $c$ . Nebo  $ab$ , nebo  $bc$ . Nemůže být prázdný z podmínky lemmatu.
5. Jakýmkoliv pumpováním se nám nemůže podařit přidat tři různé znaky, tj. podmínka je porušena.

Lemma o vkládání je vlastně ve tvaru implikace. Její kontrapositivní formu lze použít k důkazu, že nějaký jazyk *není* CFL. Stačí ukázat platnost následujícího tvrzení:

Pro libovolnou konstantu  $n$  existuje slovo  $z$ ,  $|z| > n$  takové, že pro všechna slova  $u, v, w, x, y$  splňující:  $z = uvwxy$ ,  $vx \neq \epsilon$  a  $|vwx| \leq n$  existuje takové  $i$ , že  $uv^iwx^iy \notin L$ .

### Příklad:

$$L = \{wcw \mid w \in \{a,b\}^*\}$$

Pro libovolnou konstantu  $n$  existuje slovo  $z \in L, |z| > n$ . Zvolíme slovo  $z$  jako libovolné, pro důkaz vhodné, slovo  $z$  z jazyka  $L$  -  $z = a^n b^n c a^n b^n$ . Dále pro každé libovolné rozdělení slova  $z$  splňující následující podmínky:  $z = uvwxy$ ,  $vx \neq \epsilon$ ,  $|vwx| \leq n$  musí existovat  $i \in \mathbb{N}_0$  takové, že  $uv^iwx^iy \notin L$ .

Nyní musíme takové  $i$  nalézt. Položme tedy  $i = 0$  a ověříme, že  $uwy \notin L$  rozebráním jednotlivých případů:

1.  $c$  není podslovo  $vwx$ . Potom ale  $uwy = z'ca^n b^n$  nebo  $uwy = a^n b^n cz'$ , kde  $|z'| < 2n$ . Z toho plyne, že  $uwy \notin L$ .
2.  $c$  je podslovo  $vwx$ . Tuto situaci rozdělíme ještě na další dva případy:
  - $c$  je podslovo  $vx$ : Pak ale  $c \notin uwy$ , z čehož plyne, že  $uwy \notin L$
  - $c$  je podslovo  $w$ :  $|vwx| \leq n$ ,  $uwy = a^n b^{n-|v|} c a^{n-|x|} b^n$ . Současně  $vx \neq \epsilon$  a tudíž  $|v| + |x| > 0$  a tedy  $uwy \notin L$ .

## Zásobníkové automaty

Tak jako k regulárním gramatikám existují konečné automaty, které rozpoznávají právě jazyky generované těmito gramatikami, tak i ke gramatikám bezkontextovým existují ve výše uvedeném smyslu ekvivalentní automaty – tzv. zásobníkové automaty (push-down automata – PDA). PDA si lze představit jako (nedeterministický) konečný automat s tím, že navíc obsahuje (pomocnou) paměť (a díky ní i další zdroj nedeterminismu), která pracuje jako zásobník (push-down store) a jejíž velikost není shora omezena – je tzv. *potenciálně nekonečná* v následujícím smyslu: v každém okamžiku (konečného) výpočtu je sice konečná (tj. v zásobníku je uloženo jen konečně mnoho symbolů), ale kdykoli ji můžeme rozšířit o další konečný počet paměťových míst (přidat další symboly na zásobník).

Ze vstupní pásky, na níž je zapsáno slovo nad jistou vstupní abecedou, lze pouze číst a čtecí hlava se pohybuje jen vpravo. Automat může na vrchol zásobníku ukládat symboly (opět z jisté abecedy) a takto uložené symboly může následně číst s tím, že smí číst pouze z vrcholu zásobníku: přečtený symbol je z vrcholu odstraněn (tj. systém LIFO – Last In First Out). Jinými slovy, nelze číst do hloubi zásobníku, aniž by přečtené symboly nebyly odstraněny – zásobník, u něhož naopak toto “nedestruktivní” čtení lze realizovat se v angličtině nazývá *stack*, na rozdíl od našeho *push-down store* s destruktivním čtením. Takto intuitivně popsané zařízení nyní formalizujeme.

Nedeterministický zásobníkový automat (PDA), je sedmice:

- $Q$  – konečná množina stavů
- $\Sigma$  – vstupní abeceda
- $\Gamma$  – zásobníková abeceda
- $\delta$  – přechodová funkce, ze  $(Q \times (\Sigma \times \Gamma)) \rightarrow \text{Množina konečných podmnožin } (Q \times \Gamma)$
- $q_0$  – počáteční stav
- $Z_0$  – počáteční symbol na zásobníku
- $F$  – množina koncových stavů

$\delta(q_0, a, Z_0) = \{(q_0, AZ_0)\}$ ;  $Z_0$  - dno zásobníku,  $A$  - vrchol zásobníku, přidal se v tomto kroku

$\delta(q_0, c, A) = \{(q_1, A)\}$  ... obsah zásobníku se nezměnil, pouze se přešlo do stavu  $q_1$

$\delta(q_1, b, A) = \{(q_1, \varepsilon)\}$  ... stav se nezměnil, ze zásobníku se přečetlo  $A$  – bylo odebráno  
*vrchol zásobníku běžného PDA se píše vlevo*

## Konfigurace PDA

Konfigurací PDA  $M$  se nazve trojici  $(q, w, \alpha)$ , kde

- $q$  – stav řídicí jednotky
- $w$  – nenačtená část vstupního řetězce, první symbol pod čtecí hlavou
- $\alpha$  - obsah zásobníku (vrchol zásobníku)

**Vnitřní konfigurace** (= částečná konfigurace) = aktuální stav a celý obsah zásobníku (vrchol se píše vlevo)

**Počáteční konfigurace** PDA má tvar  $(q_0, w, Z_0)$  pro slovo  $w$  z abecedy  $\Sigma$ , tj. automat je v počátečním stavu  $q_0$ , na vstupní pásce je řetězec  $w$  a v zásobníku je startovací symbol  $Z_0$ .

**Koncová konfigurace** má tvar  $(q, \varepsilon, \alpha)$ , kde  $q$  je koncový stav a  $\alpha$  je řetězec (může být i prázdný) ze zásobníkové abecedy.

## Přechod PDA

Přechod PDA se definuje jako binární relace  $\vdash$  (krok výpočtu), která je definována na množině konfigurací zásobníkového automatu  $M$ .

$(q, aw, Za) \vdash (q', w, \gamma a)$

Nachází-li se zásobníkový automat  $M$  ve stavu  $q$  a na vrcholu zásobníku je uložen symbol  $Z$ , pak po přečtení vstupního symbolu  $a$  různého od  $\varepsilon$  může automat přejít do stavu  $q'$ , přičemž se čtecí hlava posune doprava a na vrchol zásobníku se uloží po odstranění symbolu  $Z$  řetězec  $\gamma$ . Je-li  $\gamma = \varepsilon$  pak je pouze odstraněn vrchol zásobníku. Je-li  $a = \varepsilon$ , pak se neposouvá čtecí hlava a nový obsah zásobníku není určován příštím symbolem. Tento typ přechodu se nazývá  **$\varepsilon$ -přechodem**.  $\varepsilon$ -přechod může nastat i tehdy, kdy byly načteny všechny vstupní symboly.

## Rozpoznávání PDA

**Rozpoznávání koncovým stavem** – slovo  $w$  je automatem přijato, jestliže existuje možnost, že po přečtení slova  $w$  se ocitne v koncovém stavu.

$$L(M) = \{w \in \Sigma^* \mid (q_0, w, Z_0) \xrightarrow{*} (q_f, \varepsilon, \alpha), \text{ kde } q_f \in F, \alpha \in \Gamma^*\}$$

**Rozpoznávání prázdným zásobníkem** – slovo  $w$  je přijato, jestliže existuje možnost, že po zpracování slova se automat ocitne s prázdným zásobníkem. Děje se tak pomocí speciálního symbolu označujícího dno zásobníku, který PDA na začátku zapíše na zásobník.

$$L_e(M) = \{w \in \Sigma^* \mid (q_0, w, Z_0) \xrightarrow{*} (q, \varepsilon, \varepsilon), \text{ kde } q \in Q\}.$$

Z

Takto definovaný PDA je nedeterministický – akceptuje slovo, jestliže existuje **alespoň jeden výpočet**, který vede z počáteční konfigurace do akceptující. V případě možnosti automat „hádá správně“, protože nesprávná volba sama o sobě nemůže způsobit zamítnutí vstupu – ten může být zamítnut jedine tedy, pokud žádná správná volba neexistuje

Z pohledu jazyka: Jazyk rozpoznávaný koncovým stavem nebo prázdným zásobníkem. Oba způsoby jsou ekvivalentní.

## Rreprezentace konfigurací

PDA  $A = (\{q, r\}, \{a, b, c\}, \{Z, A\}, \delta, q, Z, \{r\})$  - akceptuje koncovým stavem

PDA  $A' = (\{q, r\}, \{a, b, c\}, \{Z, A\}, \delta, q, Z, \emptyset)$  - akceptuje prázdným zásobníkem

Přechodovou funkci mají oba automaty stejnou:

$$\delta(q, a, Z) = \{(q, AZ)\}$$

$$\delta(q, a, A) = \{(q, AA)\}$$

$$\delta(q, c, Z) = \{(r, Z)\}$$

$$\delta(q, c, A) = \{(r, A)\}$$

$$\delta(r, b, Z) = \{(r, \varepsilon)\}$$

$$\delta(r, b, A) = \{(r, \varepsilon)\}$$

PDA se dá ještě reprezentovat pomocí přechodového grafu (stavového diagramu)

## Rozdíl mezi zásobníkovým automatem a rozšířeným zásobníkovým automatem

Zásobníkový automat má přechodovou funkci  $\delta$  definovanou jako zobrazení z  $Q \times (\Sigma \cup \{\varepsilon\}) \times \Gamma$  do konečných podmnožin množiny  $(Q \times \Gamma^*)$ . Oproti tomu rozšířený zásobníkový automat má definovanou rozšířenou přechodovou funkci  $\delta$  jako zobrazení z konečné podmnožiny množiny  $Q \times (\Sigma \cup \{\varepsilon\}) \times \Gamma^*$  do konečných podmnožin množiny  $(Q \times \Gamma^*)$ .

Neformálně řečeno, rozšířený zásobníkový automat „vidí“ hlouběji do zásobníku – tj. čte  $0-n$  vrchních symbolů.

Ke každému rozšířenému PDA existuje ekvivalentní (obyčejný) PDA.

## Převod bezkontextové gramatiky na zásobníkové automaty

CFG a PDA jsou vzájemně převoditelné. Třída jazyků rozpoznávána PDA je právě třída bezkontextových jazyků.

### Nedeterministická syntaktická analýza

#### **Shora dolů:**

Ke každé CFG  $G$  lze sestavit PDA  $M$  takový, že  $L(G) = L_e(M)$ .

V levé derivaci je v jednom kroku odvození nahrazen (nejlevější) neterminál  $A$  pravou stranou  $X_1 \dots X_n$  nějakého  $A$ -pravidla. V  $M$  této situaci odpovídá náhrada  $A$  na vrcholu zásobníku řetězem  $X_1 \dots X_n$ . Terminální vstupy ze vstupu se načítají, pokud jsou na vrcholu zásobníku, akceptujeme prázdným zásobníkem, automat je jednostavový.

$M = (\{q\}, \Sigma, N \cup \Sigma, \delta, q, S, \emptyset)$ , kde  $\delta$  je definována:

- $\delta(q, \varepsilon, A)$  obsahuje  $(q, \alpha)$  právě když  $A \rightarrow \alpha \in P$
- $\delta(q, a, a) = \{(q, \varepsilon)\}$  pro všechna  $a \in \Sigma$

#### **Zdola nahoru:**

Nechť  $G$  je libovolná CFG, pak lze zkonstruovat rozšířený PDA  $R$  takový, že  $L(G) = L(R)$ .

Vrchol zásobníku píšeme vpravo. Konstruujeme rozšířený PDA, který simuluje pravou derivaci v  $G$  v obráceném pořadí.

PDA má kroky dvojího typu:

1. může kdykoli číst do zásobníku vstupní symbol,
  2. (redukce) je-li na vrcholu zásobníku řetěz tvořící pravou stranu nějakého pravidla v  $G$ , může ho nahradit odpovídajícím levostranným neterminálem (a ze vstupu nic nečte).
- Do koncového stavu přejdeme, pokud je na zásobníku „dno“  $S$ . Akceptuje tedy koncovým stavem.

Nechť  $G = (N, \Sigma, P, S)$ .

Položme  $R = (\{q, r\}, \Sigma, N \cup \Sigma \cup \{\perp\}, \delta, q, \perp, \{r\})$ , kde  $\perp$  je nově přidaný symbol a kde  $\delta$  je definována takto:

1.  $\delta(q, a, \varepsilon) = \{(q, a)\}$  pro všechna  $a \in \Sigma$  ...načítání vstupu na zásobník,
2. je-li  $A \rightarrow \alpha$ , pak  $\delta(q, \varepsilon, \alpha)$  obsahuje  $(q, A)$  ...redukce,
3.  $\delta(q, \varepsilon, \perp S) = \{(r, \varepsilon)\}$  ...akceptování.



zdola nahoru. Nedeterminismus se objevuje v těchto dvou základních variantách:

(1) v konfiguracích, kdy PDA má na vrcholu pravou stranu nějakého pravidla a volí zda redukovat tuto pravou stranu na odpovídající neterminál nebo zda číst ze vstupu – viz výše např.  $(q, \perp E + T, *i)$ , kde lze nejen provést uvedené čtení symbolu  $*$ , ale též redukci dle  $E \rightarrow E + T$ . Tuto situaci nazýváme konfliktem typu čtení versus redukce;

(2) v konfiguracích, kdy PDA má na vrcholu takový řetěz, že jsou možné alespoň dvě různé redukce (tj. redukce podle různých pravidel); jako příklad může opět sloužit výše uvedená  $(q, \perp E + T, *i)$ , kde lze redukovat jak  $E + T$  na  $E$ , tak i příponu tohoto řetězu, tj.  $T$ , na (shodou okolností opět)  $E$ . Tuto situaci nazýváme konfliktem typu redukce versus redukce.

Variantu (1) lze obecně charakterizovat existencí jak pravidla  $A \rightarrow \alpha$ , tak i  $B \rightarrow \alpha\beta$  (spolu s existencí například  $S \Rightarrow^* \gamma Az$  a  $S \Rightarrow^* \gamma Bz$ ), kdežto pro (2) je typická existence pravidel  $A \rightarrow \alpha$  a  $B \rightarrow \beta\alpha$  (spolu například s  $S \Rightarrow^* \gamma\beta Az$  a  $S \Rightarrow^* \gamma Bz$ ). Současný výskyt obou typů konfliktů je samozřejmě v konfiguraci PDA též možný.

Co se nedeterminismu týče, je tedy vidět, že zatímco u analýzy shora dolů se omezuje na případ, kdy máme volit, kterou z pravých stran nahradit neterminál na vrcholu zásobníku, je u analýzy zdola nahoru jeho povaha poněkud košatější.

### **Příklad syntaktické analýzy:**

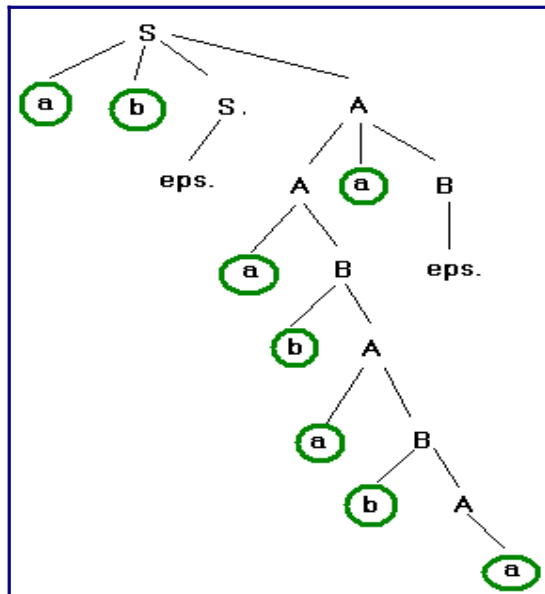
$G = (\{S, A, B\}, \{a, b\}, P, S)$

$P =$

$\{S \rightarrow \varepsilon \mid abSA\}$

$A \rightarrow AaB \mid aB \mid a,$   
 $B \rightarrow aSS \mid bA \mid \varepsilon$

Derivační strom pro slovo  $w = abababaa$



**Automat, který provádí syntaktickou analýzu shora dolů:**

$A = (\{q\}, \{a, b\}, \{S, A, B, a, b\}, \delta, q, S, \emptyset)$

2 typy přechodových fcí:

- *levou stranu pravidel z gram. dáváme na zásobník levé strany přechodové fce PDA, pravou stranu pravidel z gram. na zásobník pravé strany*

$\delta(q, \varepsilon, S) = \{(q, \varepsilon), (q, abSA)\}$

$\delta(q, \varepsilon, A) = \{(q, AaB), (q, aB), (q, a)\}$

$\delta(q, \varepsilon, B) = \{(q, aSS), (q, bA), (q, \varepsilon)\}$

- „mazací“ přechodové fce

$\delta(q, a, a) = \{(q, \varepsilon)\}$

$\delta(q, b, b) = \{(q, \varepsilon)\}$

- **Akceptující výpočet nad slovem abababaa:**

(intuice: postupuju podle derivačního stromu, sleduju jeho rozvíjení odshora a čtu ho zleva)

**vrchol zásobníku je vlevo**

$(q, abababaa, S) \mid \rightarrow (q, abababaa, abSA) \mid \rightarrow (q, bababaa, bSA) \mid \rightarrow$

$(q, ababaa, SA) \mid \rightarrow (q, ababaa, A) \mid \rightarrow (q, ababaa, AaB) \mid \rightarrow$

$(q, ababaa, aBaB) \mid \rightarrow (q, babaa, BaB) \mid \rightarrow (q, babaa, bAaB) \mid \rightarrow$

$(q, abaa, AaB) \mid \rightarrow (q, abaa, aBaB) \mid \rightarrow (q, baa, BaB) \mid \rightarrow$

$(q, baa, bAaB) \mid \rightarrow (q, aa, AaB) \mid \rightarrow (q, aa, aaB) \mid \rightarrow$

$(q, a, aB) \mid \rightarrow (q, \varepsilon, B) \mid \rightarrow (q, \varepsilon, \varepsilon)$

... celé slovo se přečetlo a zásobník se vyprázdnil  $\rightarrow$  **automat slovo akceptuje**

### Automat pro syntaktickou analýzu zdola nahoru:

$$A_2 = (\{q, r\}, \{a, b\}, \{S, A, B, a, b, \perp\}, \delta, q, \perp, \{r\})$$

3 typy přechodových funkcí:

- *terminály z gramatiky se předávají na zásobník*

$$\delta(q, a, \varepsilon) = \{(q, a)\}$$

$$\delta(q, b, \varepsilon) = \{(q, b)\}$$

- *pravou stranu pravidel z gram. dáváme na zásobník levé strany přechodové fce PDA, levou stranu pravidel z gram. na zásobník pravé strany*

$$\delta(q, \varepsilon, abSA) = \{(q, S)\}$$

$$\delta(q, \varepsilon, \varepsilon) = \{(q, S), (q, B)\} \quad \text{!!! Nesmí být rozděleno na: } \delta(q, \varepsilon, \varepsilon) = \{(q, S)\} \text{ a } \delta(q, \varepsilon, \varepsilon) = \{(q, B)\}, \text{ nebyla by to pak funkce.}$$

$$\delta(q, \varepsilon, AaB) = \delta(q, \varepsilon, aB) = \delta(q, \varepsilon, a) = \{(q, A)\}$$

$$\delta(q, \varepsilon, aSS) = \delta(q, \varepsilon, bA) = \{(q, B)\}$$

- *přechod do koncového stavu*

$$\delta(q, \varepsilon, \perp S) = \{(r, \varepsilon)\}$$

- **Akceptující výpočet nad slovem abababaa:**

(Intuice: čtu derivační strom zleva – jako když teče voda (= používám první skupinu pravidel), pokud by voda musela téct do kopce, použiju pravidlo z druhé skupiny)

**vrchol zásobníku je vpravo**

$$(q, abababaa, \perp) \mid \rightarrow (q, bababaa, \perp a) \mid \rightarrow (q, ababaa, \perp ab) \mid \rightarrow$$

$$(q, ababaa, \perp abS) \mid \rightarrow (q, babaa, \perp abSa) \mid \rightarrow (q, abaa, \perp abSab) \mid \rightarrow$$

$$(q, baa, \perp abSaba) \mid \rightarrow (q, aa, \perp abSabab) \mid \rightarrow (q, a, \perp abSababa) \mid \rightarrow$$

$$(q, a, \perp abSababA) \mid \rightarrow (q, a, \perp abSabaB) \mid \rightarrow (q, a, \perp abSabA) \mid \rightarrow$$

$$(q, a, \perp abSaB) \mid \rightarrow (q, a, \perp abSA) \mid \rightarrow (q, \varepsilon, \perp abSAa) \mid \rightarrow$$

$$(q, \varepsilon, \perp abSAaB) \mid \rightarrow (q, \varepsilon, \perp abSA) \mid \rightarrow (q, \varepsilon, \perp S) \mid \rightarrow (r, \varepsilon, \varepsilon)$$

... automat přečetl celé slovo a přešel do koncového stavu r, **slovo akceptuje**.

U nedeterministické analýzy automat slovo neakceptuje, pokud **žádný** z možných výpočtů není akceptující.

### Efektivnost syntaktické analýzy

Nedeterministický PDA  $\Rightarrow$  nedeterministický algoritmus  $\Rightarrow$  exponenciální deterministický algoritmus

#### Řešení:

- deterministický algoritmus složitosti  $O(n^3)$ , kde  $n = |w|$  (algoritmus Cocke – Kasami – Younger)
- deterministické zásobníkové automaty a deterministické bezkontextové jazyky
- lineární algoritmy pro speciální třídy deterministických bezkontextových jazyků

## Uzávěrové vlastnosti

Bezkontextové jazyky jsou uzavřené na operace **sjednocení**, **zřetězení**, **iteraci** a **pozitivní iteraci**, **průniku s regulárním jazykem**.

Nejsou uzavřeny vzhledem k operacím **průniku** a **doplňku**.

### Sjednocení:

dvě gramatiky (búno. mající disjunktní množiny neterminálů) spojíme dohromady, zavedu nový počáteční neterminál  $S$ , z kterého se půjde buď do  $S_1$  nebo do  $S_2$  (nové pravidla), ostatní pravidla se sjednotí.

Definujme  $G = (N_1 \cup N_2 \cup \{S\}, \Sigma_1 \cup \Sigma_2, P, S)$ , kde  $S$  je nový symbol a  $P = P_1 \cup P_2 \cup \{S \rightarrow S_1, S \rightarrow S_2\}$

Jazyk  $L = L_1 \cup L_2$  je generován gramatikou  $G$ .

### Zřetězení:

podobně, přidáme pravidlo  $S \rightarrow S_1 S_2$ .

### Iterace a Pozitivní iterace

Definujme  $G = (N_1 \cup \{S\}, \Sigma_1, P, S)$ , kde  $S$  je nový symbol a  $P = P_1 \cup \{S \rightarrow SS_1 | \epsilon\}$

Jazyk  $L = L_1^*$  je generován gramatikou  $G$ .

Definujme  $G = (N_1 \cup \{S\}, \Sigma_1, P, S)$ , kde  $S$  je nový symbol a  $P = P_1 \cup \{S \rightarrow SS_1 | S_1\}$

Jazyk  $L = L_1^+$  je generován gramatikou  $G$ .

### Neuzavřenost na průnik a doplněk

$$L_1 = \{a^n b^n c^m \mid m, n \geq 1\}, L_2 = \{a^m b^n c^m \mid m, n \geq 1\}$$

Kdyby byla třída bezkontextových jazyků uzavřena vzhledem k operaci průnik, pak i  $L_1 \cap L_2 = \{a^n b^n c^n \mid n \geq 1\}$  by musel být bezkontextový, což však není.

Neuzavřenost vůči doplňku plyne z uzavřenosti třídy bezkontextových jazyků vzhledem k operaci sjednocení, neuzavřenosti na průnik a De Morganových pravidel:

$$L_1 \cap L_2 = \neg(\neg L_1 \cup \neg L_2)$$